PROD arama bulguları ve öneriler

277 gerçek arama sorgusu PROD'da koşuldu, **44'ünde** beklenen sonuç gelmedi. Ayrıca 554 ham response (UAT + PROD) veri tutarlılığı açısından tarandı. Aşağıda ne görüldüğü ve ne önerildiği var; bütün örnekler gerçek response'lardan. Case bazlı detay ekteki Excel'dedir.

SORGU	BEKLENEN GELMEDİ	İLK İKİ SEBEP	DİĞER SEBEPLER
277	**44**	**31**	**13**
gerçek arama	%16	44 hatanın 31'i	dağınık, tekil

A · SIRALAMA BULGULARI

A1 · Kısa aramalarda sanatçı kayıtları listeyi dolduruyor — 20 / 44

`git`	1. Hüseyin KA**ĞIT** 2. Kırık **GİT**ar 3. Nesrin Kağıt 4. Yiğit Aktaş 5. Gitarvemavi — **Blok3 – "Git" 14. sırada**
`erik`	İlk 5'in tamamı sanatçı: **Erik Satie, Erika Lundmoen, Erika, Erikk** — **beklenen şarkı 26. sırada**
`sus`	1. Arif **SUS**am 2. Çağdaş **SUS**even 3. **Sus**an Dervishi 4. Je**sus** Phonk — **Ceza – "Suspus" listede yok**
`kömür`	1–4. sıra sanatçı: Gülşah / Serra / Abdulbaki **Kömür**, Barış **Kömür**cüoğlu — **Mabel Matiz – "Kömür" listede yok**

Ortak nokta: sorgu, sanatçı adının **ortasında** bir parça olarak geçse bile eşleşme üretiliyor — "git" araması "Ka**ğıt**" soyadını buluyor. Kısa sorgularda bu kayıtlar sayıca çok olduğu için ilk sıraları dolduruyor.

A2 · Aynı başlıklı kayıtlar arasında popülerlik belirleyici olmuyor — 11 / 44

`ey aşk`	Berkay, Zara, Eyüp Hamiş versiyonları önde — **Sezen Aksu kaydı ilk 30'da yok**
`çıt çıt çedene`	Altın Gün, Ankaralı Namık önde — **Barış Manço ilk 6'da yok**
`duydun mu`	**Yusuf Güney kaydı 15. sırada**
`perde`	Ahiyan, Ceren Gündoğdu, Çetin Dilsiz önde — **Poizi – "PERDE" ilk 30'da yok**

Ölçülen mekanizma: birebir başlık eşleşmesine verilen puan popülerlik teriminden çok daha büyük olduğu için skorlar birbirine yapışıyor. **129 sorguda ardışık iki sonucun skoru birebir aynı** — `mebrure` aramasında 28 sonucun skoru birebir aynı, `türkçe` 'de 21'i. Bu durumda sıra Elasticsearch'ün iç sırasına kalıyor, yani koşudan koşuya değişebilir. Ayrıca 6 sorguda ilk ile son sonucun skor farkı **%10'un altında** (`yazan kalem siyah` → %3,2): liste sıralı görünüyor ama ayrım gücü yok.

A3 · Aynı kayıt sonuç listesinde iki kez dönüyor — 17 sorgu · PROD'a özel

`yalnızlığın çaresini`	`id=5334730` "Yalnızlığın Çaresini Bulmuşlar" **1. ve 4. sırada** · `id=5334736` 5. ve 18. · `id=5334734` 6. ve 19.
`hadi ya`	`id=5904840` "Yatıya" **1. ve 10. sırada**
`çölüme yağmur`	`id=4678893` "Affet" 7. ve 14. · `id=6354656` "Dinle" 6. ve 15.

Aynı doküman ID'si aynı listede birden fazla kez. Top-10'da 2–3 slot boşa gidiyor. **UAT'ta bu hiç olmuyor (0 sorgu)** — yani birleştirme aşamasında tekilleştirme PROD'da devrede değil.

A4 · Şarkısı olmayan sanatçı kayıtları ilk 5'te — 93 kez

`halay`	5. sırada **"Sözsüz Süper Halaylar"**
`spor`	4. sırada **"SPORA"** · `dans` 3. sırada **"Dans"** · `80` 5. sırada **"80M"**

Hepsinin `popularSongCount = 0`. Kullanıcı tıkladığında boş sanatçı sayfası açılıyor. 277 sorgunun ilk 5 sonucunda PROD'da 93, UAT'ta 73 kez.

B · VERİ BULGULARI — ARAMA MOTORUNDA DEĞİL, KATALOGDA

Bu bölümdeki her sayı yeniden üretilebilir. Depoda `dogrulama/kanit_uret.py` scripti 554 ham response dosyasını okuyup aşağıdaki bütün sayıları yeniden hesaplar ve her satır için kaynak JSON dosyasının adını yazar. Çıktısı: `dogrulama/KANIT_B1_B2.txt` .

B1 · Ad alanları bozuk — dört ayrı biçimde

ETL

diakritik kaybı	Aynı kayıt, PROD'da adı diakritiksiz: `id=619576` UAT'ta **Çelik** / PROD'da **celik** · `id=617350` UAT'ta **Beyoncé** / PROD'da **Beyonce**. Mükerrer kayıt değil — **aynı ID**. 3244 ortak sanatçı kaydının **11'inde**: İrem→Irem, Şilan→Silan, Gülden Karaböcek→GULDEN KARABOCEK, Rüya→RuYA, Sena Şener→Sena Sener, Sôra→Sora, Şebnem→Sebnem, Tunay Cöke→Tunay Coke. Ters yönde (PROD'da var, UAT'ta yok) 5 kayıt daha var.
unicode formu	Gözle aynı, **byte olarak farklı**. "Cengiz Kurtoğlu" adındaki `ğ` — UAT: `U+011F` (15 karakter) · PROD: `U+0067` + `U+0306` , g + birleştirici işaret (16 karakter). Tip farkı değil, ikisi de string; **Unicode normalizasyon formu** farklı (NFC / NFD). PROD'da **49 kayıt** NFD (27 şarkı, 19 albüm, 3 sanatçı), UAT'ta 6.
karakter kaybı	Kodlanamayan harf `?` olmuş: `id=1906144` **Şövk?t ?l?kb?rova** (Şövkət Ələkbərova) · `id=841690` **Ra?f** · `id=1315647` **Romani?a**. Bu kayıtlar **doğru adıyla aranarak bulunamaz** — "Şövkət Ələkbərova" araması aynı sanatçının başka bir kaydını (`id=1527654`) döndürür, bozuk olanı değil. Bozuk kayıt PROD'da `kökl` aramasının 20. sırasında görünüyor.
görünmez karakter	Sonda görünmez TAB karakteri: **Dilan Çıtak** `<TAB>` , **Asuman Krause** `<TAB>` , **Maya Perest** `<TAB>` (**7 ad**) · sonda NBSP (U+00A0): **Al 1'de Burdan Yak** `<NBSP>` , **Yabancı** `<NBSP>` (**5 ad**) · çift boşluk: **'Heijan Muti'**, **'Les Patrons'** (12 ad) · çift-encode: **Aleyna KalaycÃ±oÄŸlu**, **MylÃ¨ne Farmer** (PROD 2, UAT 7) · 1 playlist adı tamamen boş

Kullanıcı bunu görüyor: arama sonucunda ekranda "celik", "GULDEN KARABOCEK", "RuYA", "BeyoncÃ©", "Şövk?t ?l?kb?rova" yazıyor. Ayrıca NFD ve TAB'lı kayıtlar `performerName.exact` gibi exact-match alanlarında **hiç eşleşmez** — kullanıcı klavyesi NFC üretir ve sonda TAB yazmaz.

B2 · `popularity` alanı index'ler arasında aynı ölçekte değil

ölçek

songs	`popularity` medyan **0,80** → maksimum **2083,9** — ham sayaç, **2610 kat** aralık
videos	medyan **10,9** → maksimum **2464,2** (226 kat) — yine ham sayaç
performers	medyan **15** → maksimum tam **100** — **normalize edilmiş**
albums	medyan **1** → maksimum tam **100** — **normalize edilmiş**
performer Popularity	medyan **251** → maksimum **56 341** (224 kat)
popularity2	PROD'da medyan 31,5 / maksimum 100; UAT'ta aynı alan medyan 2,3 / maksimum 75,2 — **iki ortamda farklı ölçek**

Aynı alan adı, farklı anlam: `popularity` performers ve albums index'lerinde 0–100'e normalize edilmiş, songs ve videos'ta ise ham sayaç. Skorlama formülü bu alanı index'ler arası ortak bir terim gibi kullanıyorsa, songs tarafındaki birkaç uç kayıt tüm skoru domine eder (medyan 0,80 iken maksimum 2083,9). UAT tarafındaki `prodPopularity` her yerde 0–100 aralığında; PROD'da bu alan hiç yok.

C · KÖK NEDEN — B BULGULARI NEREDEN GELİYOR

11.208 ortak kayıt (aynı index, aynı `id` , aynı alan) iki ortamda yan yana karşılaştırıldı.
Bozukluk tek bir yerden gelmiyor:

	iki ortamda AYNI (kaynakta bozuk)	sadece PROD'da (PROD yolunda bozuldu)
NFD formu	3	**21**
diakritik kaybı	0	**11**
boşluk / TAB / NBSP	**22**	1
mojibake (MylÃ¨ne)	**2**	0
? karakteri	**1**	0

1 · Kaynak katalogda zaten bozuk

provider / ETL girişi

Bu kayıtlar **iki ortamda birebir aynı**, yani bozulma UAT/PROD ayrımından önce olmuş.

mojibake	UTF-8 byte'ları Latin-1 olarak okunmuş — bir sınırda charset belirtilmemiş. **Onarılabilir:** `new String(s.getBytes(ISO_8859_1), UTF_8)`
? kaybı	`ə` (Azerice schwa) hedef code page'de temsil edilemediği için `?` yazılmış. **Onarılamaz** — harf bilgisi yok, kaynaktan yeniden çekilmeli.

2 · PROD ingest yolu UAT'tan farklı

32 kayıt

21 NFD + 11 diakritik kaybı: **UAT'ta doğru, PROD'da bozuk, aynı ID.** Kaynak doğruyu vermiş — UAT bunun kanıtı. Veriden ayırt edilemeyen iki olasılık: iki ortam aynı kod/config ile yüklenmiyor, ya da farklı zamanlarda farklı snapshot'tan yüklendi.

PROD'da NFD oranı hiçbir provider'da yığılmıyor — `12` %0,34 (27/7883) · `4` %0,58 (16/2742) · `1` %0,27 (5/1868) · `17` %0,06 (1/1578) · diğerleri %0. Belirli bir provider bozuk olsa oran orada patlardı. Ayrışan işaretler de tam Türkçe seti — cedilla 28 (ç, ş), diaeresis 28 (ö, ü), dot-above 18 (İ), breve 11 (ğ), yabancı yalnızca 2. Yani `Ş` 'yi `S` +çengel olarak yazan bir aşamadan geçmiş; **pipeline'da normalizasyon adımı hiç yok.**

3 · Neden bugüne kadar hiç görülmedi

%0,26 oran

gözle görünmez	NFD ekranda tespit edilemez — `Şahin` ile `Şahin` aynı görünür. Sadece program görebilir.
test tolerant	`MuudSearchUtils.equalsTRInsensitive` karşılaştırma öncesi `.trim()` + **NFC** uyguluyor — doğru tasarım, yoksa her kozmetik fark relevance hatası gibi görünürdü. Ama tam bu tolerans NFD ve sondaki TAB kayıtlarını 554 response boyunca tek NOK üretmeden geçirdi.
oran düşük	18.806 kayıtta 49 NFD — elle bakan biri 400 kayıtta bir tanesine denk gelir.

Relevance testi tolerant olmalı, veri kalitesi denetimi olmamalı — iki ayrı iş. İkincisi depoda: `analyzer.VeriKalitesiDenetimi`.

Kendiniz deneyin

3 adım

1	İki ortamda da `{"text":"melike"}` at, Ctrl+F `9204953` → `songs` 8. sıra. **UAT 26 karakter** (`Ş` = U+015E) · **PROD 27 karakter** (`S` + U+0327). Ekranda birebir aynı.
2	PROD response'unda Ctrl+F → **klavyeden** `Şahin` yaz (kopyalama — kopyalarsan bozuk hali kopyalanır). **No results.** Metin gözünün önünde ama arama bulamıyor; exact-match alanlarının neden eşleşmediği bu.
3	PROD'a `{"text":"kök$l"}` at, Ctrl+F `1906144` → `performers` 20. sıra, **Şövk?t ?l?kb?rova**. Aynı kayıtta `performerCompletion.input` ve `muud_dym` de aynı bozuk metni taşıyor — otomatik tamamlama ve "bunu mu demek istediniz" de bozuk veriyle çalışıyor.

Sayı olarak görmek isterseniz Postman → Scripts → Post-response:

```
const s = pm.response.json().songs.content
  .find(h => h.data.id === "9204953").data.songName;
console.log("uzunluk", s.length, "| NFC mi", s === s.normalize("NFC"));
console.log([...s].map(c => "U+" + c.codePointAt(0).toString(16)
  .toUpperCase().padStart(4,"0")).join(" "));
```

Send → Console (Ctrl+Alt+C). PROD: `uzunluk 27 | NFC mi false` · UAT: `uzunluk 26 | NFC mi true`

D · ÖNERİLER

Ö1 performerName kısmi eşleşmesine minimum kapsama oranı

A1 · 20 case

NEREDE	performers index tanımı → `performerName` partial match
NE YAP	Sorgu, performer adının en az **%60**'ını kapsamıyorsa bu kayıt için aday üretilmesin. "git" (3 harf) → "Kağıt" (5 harf) eşleşmesi bu şartla elenir.
YAPMA	performers `topHitsScoreWeight` değerini (0.38) düşürmeyin — sanatçı adının bir parçasıyla arama yapan **44 testlik ayrı bir aile** (Sanatçı · Kısmi Ad) bundan olumsuz etkilenir. Sorun ağırlıkta değil, aday üretiminde.
DOĞRULA	`git` , `erik` , `sus` , `kömür` sorgularında şarkı kaydı ilk sıralara çıkmalı.

Ö2 Birebir başlık bonusunu indir, ikincil sıralama anahtarı ekle

A2 · 11 case + 129 sorgu

NEREDE	songs index tanımı → `scriptSource` tier bonusu / `tierRankingEnabled`
NE YAP	Birebir başlık bonusunu popülerlik katkısıyla aynı büyüklük mertebesine getirin. Ayrıca skorlar eşitlendiğinde devreye girecek bir **ikincil sıralama anahtarı** tanımlayın (popülerlik, sonra kayıt id) — şu anda eşit skorlu kayıtların sırası belirsiz.
YAPMA	songs `topHitsScoreWeight` değerini (0.27) yükseltmeyin — şarkı sözü ve kısmi başlık aramalarını bozar.
DOĞRULA	`ey aşk` → Sezen Aksu, `çıt çıt çedene` → Barış Manço 1. sıraya çıkmalı; `mebrure` sorgusunda aynı skoru paylaşan 28 kayıt kalmamalı.

Ö3 Birleştirme aşamasında tekilleştirme (dedup)

A3 · 17 sorgu

NEREDE	Cross-index birleştirme — topHits üretimi
NE YAP	Birleşik listeye eklenirken doküman **ID bazında** tekilleştirin. Aynı ID ikinci kez geldiğinde atlanmalı.
DOĞRULA	`yalnızlığın çaresini bulmuşlar` sorgusunda tekrar eden 3 ID kalmamalı; UAT'ta zaten 0.

Ö4 İçeriği olmayan sanatçı kayıtlarını sonuçlardan çıkar

A4 · 93 kez

NEREDE	performers index — sorgu filtresi
NE YAP	`popularSongCount = 0` olan sanatçı kayıtları sonuçlara girmesin, ya da en azından ilk sıralara çıkmasın.
DOĞRULA	`halay` , `spor` , `dans` sorgularında ilk 5'te boş sanatçı kaydı kalmamalı.

Ö5 Katalog metin alanlarını normalize et

B1 · veri / ETL

NEREDE	Katalog / ETL — arama motoru tarafında değil
NE YAP	Index'e yazmadan önce tek bir fonksiyon: **NFC**'ye çevir (diakritikler korunur) → baş/son kırp → TAB/NBSP/ZWSP sil → çift boşluğu teke indir → çift-encode'u onar. **Aynı fonksiyon** `performerCompletion.input` ve `muud_dym` alanlarına da uygulanmalı — onlar da aynı bozuk metni taşıyor.
AYRICA	Charset'i her sınırda açıkça UTF-8 verin (dosya okuma, HTTP, JDBC, JVM) — mojibake ve `?` sınıflarının ikisi de "charset belirtilmemiş" hatasından geliyor. Kelime içinde `?`, boş ad ve mojibake deseni **sessizce index'lenmesin**, karantinaya alınıp raporlansın.
EMNİYET AĞI	Analyzer zincirine `icu_normalizer` (name: nfc), exact alt alanlarına normalizer. Bu **bulunabilirliği** düzeltir, **ekranda görüneni düzeltmez** — o `_source`'tan geliyor. İki ayrı semptom, ikisi de gerekli.
DOĞRULA	`çelik` → **Çelik**, `beyonce` → **Beyoncé** dönmeli; `melike` sorgusunda `id=9204953` iki ortamda da 26 karakter olmalı; katalogda sonda TAB/NBSP taşıyan ad ve `Ã` / `Ã` / `Ã` dizisi kalmamalı.

Ö6 Popülerlik alanlarını tek ölçeğe getir

B2 · ölçek

NEREDE	Katalog / ETL + skorlama formülü
NE YAP	`popularity` alanını bütün index'lerde aynı ölçeğe getirin (performers/albums'te zaten 0–100; songs ve videos'ta ham sayaç) ve iki ortamda **aynı alanı** kullanın. Şu anda songs'ta medyan 0,80 iken maksimum 2083,9 — birkaç kayıt tüm skoru domine edebiliyor.
DOĞRULA	Aynı sorgu iki ortamda koşulduğunda popülerlik terimi karşılaştırılabilir olmalı.

E · TEST ORTAMI PROD'U TEMSİL ETMİYOR

Aynı 277 sorgu UAT'ta da koşuldu. İki ortamda toplam **67 farklı** sorgu hata veriyor, yalnızca **17'si ortak**. Ölçülen farklar:

	UAT	PROD	
performers	0.38	~0.41	
playlists	**0.335**	**~0.18**	← UAT'ta songs'un ÜSTÜNDE, PROD'da ALTINDA
songs	0.27	~0.27	
albums	0.15	~0.15	
videos	**0.00**	**~0.27**	
popülerlik alanı	**prodPopularity**	**popularity**	(prodPopularity PROD'da hiç yok)

Sonuca yansıması: topHits'te dönen kayıt tipi dağılımı — playlists UAT 877 / PROD 281, albums UAT 475 / PROD 172, performers UAT 2552 / PROD 2895.

tier kullanımı da farklı. `tier` sıralamada birincil anahtar (554 sorgunun tamamında artan, hiç istisna yok): tier 1'e düşen kayıt, skoru ne olursa olsun tier 0'daki herkesin altına iner. PROD'da **562 performers + 64 albums** kaydı tier ≥ 1; UAT'ta performers ve albums'te **hiç yok** (yalnızca 5 songs kaydı tier 2).

Response şeması da farklı. UAT'ta olup PROD'da olmayan: `playlist_groups` index'inin tamamı, `prodPopularity`, `manualScoreBoostTime`. PROD'da olup UAT'ta olmayan: `videos` altında `popularity2`, `popularityScore`, `performerPopularity2`, `createTime`. Ayrıca aynı alan iki tip dönebiliyor: `songsPopularity` (float / string), `songs[].songId` (int / string), `genreId` (int / string) — katı tipli bir istemci bunlarda parse hatası alır.

UAT tarafında ayrı bir sorun: `isActive = false` olan **34 kayıt** UAT sonuçlarında dönüyor; PROD'da bu hiç olmuyor.

> **PROD'daki 27 hata test paketinde hiç görünmüyor.** Ağırlık tablosu, tier davranışı ve popülerlik alanı eşitlenmediği sürece testin verdiği yeşil sonuç, kullanıcının gördüğü davranışı doğrulamıyor.

MUUD Search · PROD relevance 277 sorgu · 44 bulgu · 554 response tarandı

Ek: MUUD_Search_UAT_vs_PROD_20260904.xlsx · dogrulama/KANIT_B1_B2.txt